



Tecnológico de Monterrey

**Instituto Tecnológico y de Estudios Superiores de Monterrey
Campus Puebla**

Analítica de datos y herramientas de inteligencia artificial II (Gpo 101)

Actividad AG_1.1

Estudiante:

Jorge Alberto Cortes Sánchez | A01736236

26/09/2025

1. Importación y exploración inicial


- Se utilizó pandas, numpy y matplotlib para el análisis de datos.
- Se cargó el archivo 01_DiatomInventories_GTstudentproject_B.csv.
- Se revisaron los valores nulos en el dataset, detectando la necesidad de limpieza.

2. Identificación de variables

- Se clasificaron las columnas en:
Cuantitativas (numéricas) para análisis estadístico.
Cualitativas (categóricas) para análisis de frecuencia y agrupamiento.

3. Análisis de valores atípicos

- Se generaron boxplots para las variables numéricas, evidenciando la presencia de outliers.
- Se calcularon límites con la regla de ± 3 desviaciones estándar para detectar valores extremos.
- Se creó un nuevo dataset filtrado sin esos outliers.



4. Imputación de valores nulos

- A los valores faltantes se les aplicó la técnica de imputación por mediana, con redondeo a una cifra decimal.
- Esto permitió mantener la consistencia en las variables numéricas sin eliminar registros.

5. Construcción del dataset limpio

- Se combinaron las variables cualitativas con las cuantitativas ya limpias, generando un nuevo DataFrame (Datos_limpios).
- Se verificó que los nulos habían sido correctamente tratados.

6. Análisis de frecuencias

- Se generaron tablas de frecuencia para:
 - **TaxonName** (nombres de taxones).
 - **TaxonCode** (códigos de taxones).
- Se aplicaron filtros para mostrar solo las categorías con **más de 20,578 registros**, resaltando las más frecuentes.

7. Visualizaciones


- Se realizaron gráficos:
 - **Barras** para las categorías más frecuentes de TaxonName
 - **Área** para las categorías más frecuentes de TaxonCode.

Conclusiones

- El dataset pasó de estar incompleto y con valores extremos a uno más confiable y consistente gracias a la imputación y filtrado de outliers.
- La estrategia de usar la mediana permitió una mejor representación central de los datos.

- Las variables categóricas más frecuentes (TaxonName y TaxonCode) fueron identificadas y representadas gráficamente, lo que facilita futuros análisis de patrones.
- El proceso aplicado asegura que este dataset puede ser usado en análisis posteriores o modelos predictivos sin arrastrar problemas de calidad en los datos.


Anexos y Hallazgos



Achnanthes minutissima es la especie más frecuente, con más de **42,000 registros**, lo que indica que es la más representativa del conjunto de datos.

Le siguen **Amphora pediculus**, **Cocconeis euglypta**, **Sellaphora nigris** y **Navicula cryptotenella**, cada una con valores cercanos a **38,000–40,000 registros**, lo que refleja una presencia significativa en el ecosistema estudiado.

Conforme avanza la lista hacia la derecha, se observa una **disminución gradual en la frecuencia**, llegando hasta valores cercanos a **21,000–23,000 registros** en especies como **Gomphonema minutum**.




La gráfica muestra la frecuencia de diferentes **códigos de taxones (TaxonCode)** dentro del dataset.

Achmi02 es el taxón más frecuente con más de **43,000 registros**, lo que indica que es el más dominante.

Le siguen **Coccu01** (~39,000), **Navcr09** (~38,000) y **Vibtr01** (~31,000), que también tienen una representación alta pero con una ligera tendencia descendente.

A partir de **Navpe05** en adelante, se observa una **disminución más marcada**, llegando a ~21,000 registros en **Reisi01**.



El gráfico muestra que el conteo está distribuido de manera relativamente uniforme en las fechas presentadas, sin que ninguna de ellas domine con una porción significativamente mayor que las demás, aunque el 11 de julio de 2013 es el valor más alto.